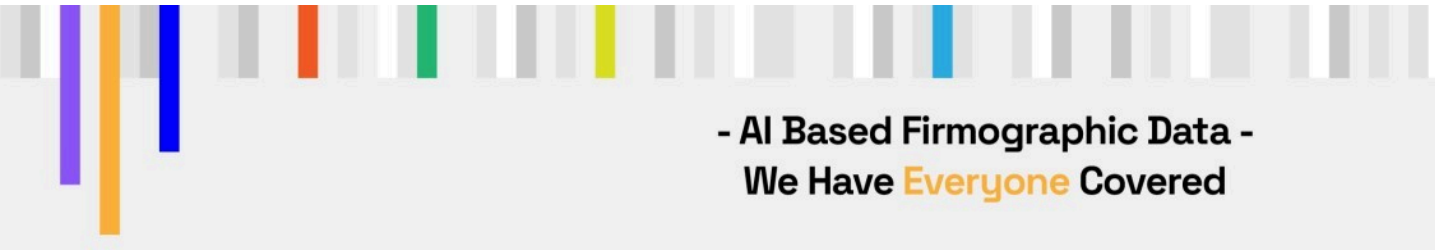

Veridion – Data Analysis & Quality Control

Pregătit de: **Caramaliu Ioana Alexandra**

1. Probleme identificate în date

A. Potriviri irelevante (noise)

Motorul a returnat uneori companii fără nicio legătură cu inputul:

- BB Connect (TH) → companii din Nigeria, Africa de Sud, Germania
- Cisco International (UK) → magazin hardware din Singapore
- Ziff Davis Ireland → site-uri VPN găzduite pe *pages.dev*

> **Impact:** risc ridicat de false positives dacă nu există QC uman.

B. Inconsistențe între industrie și descriere

- Zalaris → uneori apare ca “tax preparation services”
- Cisco → apare ca “hardware store”
- Ziff Davis → apare ca “photographic activities”

> **Impact:** clasificarea automată a industriei nu este de încredere.

C. Duplicate / multiple variante pentru aceeași companie

- Ziff Davis → 4 rânduri diferite
- Zalaris → 3 rânduri
- Kearney → 3 rânduri

- BCD Travel → 3 rânduri

> **Impact:** clientul poate primi aceeași companie de mai multe ori cu date diferite.

D. Probleme de encoding

Caractere corupte precum: `Ã¸` , `Ã¥` , `Ã¤` , `Ã©`

> **Impact:** afectează căutarea, afișarea și matching-ul.

E. Coordonate geografice invalide

Exemple: `59.355.838.899.999.900`

> **Impact:** imposibil de folosit pentru mapare sau analize geo.

F. Domenii web suspecte

Exemple: `zyzvpn.pages.dev` , `mianfei-yongjiu.pages.dev`

> **Impact:** risc reputațional dacă sunt livrate ca site-uri oficiale.

2. Recomandări de curățare și standardizare (simplificat)

2.1. Folosirea țării și orașului ca filtru principal

Dacă inputul este din Finlanda, candidații din Nigeria, Mexic sau Africa de Sud se elimină automat. Este cel mai simplu și eficient filtru.

2.2. Validarea website-ului

Domeniile oficiale sunt cele mai sigure (`cisco.com` , `ziffdavis.com` , `kearney.com`). Domeniile gratuite sau ciudate (`*.pages.dev`) trebuie marcate ca suspecte.

2.3. Alegerea unui singur “master record” pentru companiile globale

Pentru companii mari (Cisco, Ziff Davis, Kearney, Zalaris), păstrezi un singur rând principal și tratezi restul ca variante sau filiale.

2.4. Normalizarea textului

Conversie la UTF-8, corectarea caracterelor corupte și curățarea simbolurilor ciudate.

2.5. Curățarea coordonatelor

Eliminarea punctelor în plus și verificarea dacă valorile sunt în intervalul normal.

2.6. Recalcularea industriei

Industria trebuie verificată manual pe baza descrierii și website-ului, nu doar pe codurile automate.

3. Rezultatul final pentru client

După aplicarea pașilor de mai sus, datasetul final va avea:

- Un singur rând per companie reală (fără duplicate)
- Industrie corectă, bazată pe descriere și website
- Website-uri valide, fără domenii suspecte
- Adrese și coordonate curate
- Legături clare între entitățile locale și grupul global
- Zero noise (fără companii din alte țări sau industrii greșite)
- Date consistente, curate și gata de folosit în analize